

SVEUČILIŠTE U ZAGREBU

FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

*Nikola Colnar, Mislav Hlupić*

**Metoda za rekonfiguraciju izbornih  
jedinica s implementacijom u  
kontekstu izbornog sustava  
Republike Hrvatske**

Zagreb, 2025.

Ovaj rad izrađen je na Zavodu za automatiku i računalno inženjerstvo pod vodstvom dr. sc. Branimira Pervana i predan je na natječaj za dodjelu Rektorove nagrade u akademskoj godini 2024./2025.

# Sadržaj

|                                                                    |           |
|--------------------------------------------------------------------|-----------|
| <b>Popis slika</b>                                                 | <b>iv</b> |
| <b>Popis tablica</b>                                               | <b>v</b>  |
| <b>1 Uvod</b>                                                      | <b>1</b>  |
| <b>2 Izborni sustavi</b>                                           | <b>3</b>  |
| 2.1 Vrste izbornih sustava . . . . .                               | 3         |
| 2.1.1 Razmjerni sustav . . . . .                                   | 3         |
| 2.1.2 Većinski sustav . . . . .                                    | 4         |
| 2.1.3 Mješoviti sustav . . . . .                                   | 5         |
| 2.2 Proporcionalnost izbornog sustava . . . . .                    | 5         |
| 2.3 Izborni sustav Republike Hrvatske . . . . .                    | 6         |
| <b>3 Algoritam i Implementacija</b>                                | <b>7</b>  |
| 3.1 Definicija problema i priprema podataka . . . . .              | 7         |
| 3.2 Opis faza algoritma . . . . .                                  | 10        |
| 3.2.1 Faza inicijalne konstrukcije rješenja . . . . .              | 11        |
| 3.2.2 Faza projekcije i lokalne optimizacije . . . . .             | 12        |
| 3.3 Zaključak . . . . .                                            | 22        |
| <b>4 Simulacija alternativnih izbornih sustava</b>                 | <b>23</b> |
| 4.1 Nedijeljene komponente izbornih listi . . . . .                | 23        |
| 4.2 Koncentracija vlasti i Herfindahl-Hirschmanov indeks . . . . . | 26        |
| <b>5 Rezultati</b>                                                 | <b>27</b> |
| 5.1 Simulirani većinski sustavi . . . . .                          | 27        |
| 5.2 Osvojeni mandati . . . . .                                     | 30        |

|                     |           |
|---------------------|-----------|
| <b>6 Zaključak</b>  | <b>32</b> |
| <b>7 Literatura</b> | <b>34</b> |

## Popis slika

|    |                                                                                            |    |
|----|--------------------------------------------------------------------------------------------|----|
| 1  | Primjer Voronoi dijagrama. . . . .                                                         | 8  |
| 2  | Identifikacija mosta - čvor koji razdvaja klaster na dva dijela . . .                      | 15 |
| 3  | Primjer ne-mostnog čvora (susjedi ostaju međusobno povezani<br>nakon uklanjanja) . . . . . | 16 |
| 4  | Čvor s više od tri susjeda u Voronoi dijagramu. . . . .                                    | 17 |
| 5  | Simetrijski artefakti nastali zbog diskretizacije prostora. . . . .                        | 18 |
| 6  | 3D površinski graf funkcije cijene . . . . .                                               | 21 |
| 7  | Primjer različitog sastava listi u 5 izbornih jedinica . . . . .                           | 23 |
| 8  | Podjela na 100 jedinica . . . . .                                                          | 27 |
| 9  | Podjela na 110 jedinica . . . . .                                                          | 28 |
| 10 | Podjela na 120 jedinica . . . . .                                                          | 28 |
| 11 | Podjela na 130 jedinica . . . . .                                                          | 29 |
| 12 | Podjela na 140 jedinica . . . . .                                                          | 29 |

## Popis tablica

|   |                                                                   |    |
|---|-------------------------------------------------------------------|----|
| 1 | Osvojeni mandati u većinskim sustavima . . . . .                  | 31 |
| 2 | Gallagherov i Herfindahl-Hirschmanov indeks za simulirane sustave | 31 |

# 1 Uvod

Parlamentarni izbori jedan su od temeljnih procesa demokratskih društvenih uređenja kroz koje građani izravno utječu na sastav zakonodavne vlasti svoje države. Izborni sustavi predstavljaju mehanizme prema kojima se glasovi birača preračunavaju u političku zastupljenost u parlamentu, odnosno mandate. Svaki izborni sustav specifično utječe na političku dinamiku zemlje i na razinu zastupljenosti različitih društvenih skupina te na legitimitet i stabilnost parlamentarne vlasti. Različiti modeli mogu dovesti do značajnih razlika u raspodjeli moći među političkim opcijama, a time i do različitih oblika političke participacije i ravnoteže [1] [2].

Izborni sustavi mogu se podijeliti u tri osnovne skupine: većinski, razmjerni i mješoviti. Svaki od sustava ima vlastite prednosti i nedostatke te može u značajnijoj mjeri utjecati na rezultate parlamentarnih izbora. Danas se u Republici Hrvatskoj primjenjuje razmjerni izborni sustav s D'Hondtovom metodom raspodjele mandata, dok se na prvim višestranačkim izborima 1990. godine koristio većinski sustav [3]. Sustav je od tada ostao stabilan i relativno neizmijenjen uz iznimku donošenja Zakona o izbornim jedinicama za izbor zastupnika u Hrvatski Sabor u rujnu 2023. godine.

Unatoč tome, hrvatski je izborni sustav često predmet stručnih i javnih kritika. D'Hondtova metoda načelno favorizira veće stranke, dok visoki nominalni izborni prag od 5 % otežava ulazak manjih stranki u parlament. Dodatno, cenzus od 10 % za priznavanje preferencijalnih glasova umanjuje utjecaj birača na izbor pojedinih zastupnika. Problem je predstavljala i dugogodišnja neusklađenost izbornih jedinica s načelom ujednačenosti od  $\pm 5\%$ , dok nove jedinice iz 2023. godine, iako zadovoljavaju to načelo, ne poštuju administrativne granice županija, a u pojedinim slučajevima narušavaju

teritorijalni kontinuitet i izazivaju nelogičnosti u teritorijalnom obuhvatu. Uz sve navedeno, relativno visok Gallagherov indeks ukazuje na ograničenu razmjernost postojećeg sustava, odnosno na odstupanje između udjela glasova i broja osvojenih mandata.

Upravo zbog navedenih nedostataka, a potaknuti nastojanjem da se poveća povezanost zastupnika i građana te znanstvenim interesom za usporedbu različitih izbornih modela, u ovom radu analiziramo mogućnost primjene većinskog sustava u hrvatskom kontekstu. Na temelju službenih rezultata parlamentarnih izbora iz 2024. godine i službenih GIS podataka Republike Hrvatske proveli smo simulaciju u kojoj smo pretpostavili izborni sustav s jednomandatnim izbornim jedinicama. U okviru simulacije razvili smo pristup temeljen na algoritmu KaFFPa, uz vlastite nadogradnje, kako bismo konstruirali podjelu izbornih jedinica koja zadovoljava ustavna i zakonska ograničenja. U skladu s Ustavom, simulacije su izvedene za raspon od 100 do 160 zastupnika, pri čemu su izuzeti zastupnici manjina i dijaspora, čime se promatra 100 do 140 mandata teritorijalne RH. Rezultati pokazuju da je moguće ostvariti takvu podjelu.

Struktura rada je sljedeća. Nakon uvodnog poglavlja, u drugom je poglavlju dan kratak pregled izbornih sustava. Treće poglavlje opisuje korištenu metodologiju, algoritme i implementacijske prilagodbe. Četvrto poglavlje opisuje simulaciju izbora i koncentraciju vlasti, dok su u petom poglavlju prikazani i analizirani rezultati simulacije. Konačno, u šestom poglavlju iznose se zaključci rada.



## 2 Izborni sustavi

Izborni sustav je skup pravila, mehanizama i postupaka kojima se uređuje način provođenja izbora, odnosno način na koji birači izražavaju svoje političke preferencije kroz glasovanje i kako se ti glasovi pretvaraju u mandate, odnosno broj mjesta u predstavničkim tijelima [4].

### 2.1 Vrste izbornih sustava

#### 2.1.1 Razmjerni sustav

Razmjerni ili proporcionalni izborni sustav (engl. *proportional representation*) je vrsta izbornog sustava u kojem se mandati u predstavničkom tijelu raspodjeljuju političkim strankama ili listama razmjerno broju osvojenih glasova na izborima. Ovaj sustav osmišljen je s ciljem da politička zastupljenost u parlamentu što vjernije odražava volju birača na izborima. Birači u ovakvom sustavu najčešće glasaju za stranačke liste, uz mogućnost preferencijalnog glasanja za pojedinog kandidata unutar liste. Birači unutar liste kandidata mogu dati glas za određenog kandidata, čime imaju direktniji utjecaj na to koji će kandidat s liste biti izabran.

U razmjernim sustavima razlikujemo:

- Zatvorene liste - birači glasaju isključivo za listu, a redoslijed kandidata određuju isključivo stranke, odnosno koalicijski partneri;
- Otvorene liste - birači mogu dati preferencijalni glas određenom kandidatu na listi, čime se može promijeniti poredak kandidata unutar liste te utjecati na izbor konkretnog kandidata;
- Poluotvorene liste - Slično otvorenim listama, ali uz postojanje cenzusa

glasova koji kandidat mora skupiti kako bi preuzeo povoljniju poziciju na listi.

Hrvatski sustav koristi poluotvorene liste. Birači od 2015. godine mogu dati jedan preferencijalni glas kandidatu. Ako kandidat osvoji barem 10 % glasova liste, može *preskočiti* ostale kandidate na listi od kojih je osvojio veći broj preferencijalnih glasova [5].

Mandati se dijele prema udjelu osvojenih glasova, koristeći različite matematičke metode. Najčešće korištene metode su D'Hondtova metoda, koja se temelji na dijeljenju broja glasova svake stranke nizom cijelih brojeva, pri čemu se mandati dodjeljuju prema najvećim dobivenim kvocijentima te Websterova, odnosno Sainte-Laguë metoda, koja ravnomjernije raspodjeljuje mandate između većih i manjih stranki. Osim njih, u primjeni je i Hareova kvota, kod koje se broj ukupnih važećih glasova dijeli s brojem mandata, a zatim se svakom izbornom sudioniku dodjeljuje onoliko mandata koliko puta njegova ukupna podrška sadrži taj kvocijent. Često postoji i nominalni prag glasova koji stranka mora osvojiti kako bi sudjelovala u postupku raspodjele mandata. Ovime se sprječava prevelika fragmentacija parlamenta. U Republici Hrvatskoj nominalni izborni prag postavljen je na 5%.

### **2.1.2 Većinski sustav**

U većinskom izbornom sustavu (engl. *majoritarian systems*) kandidat ili stranka pobjeđuje ako osvoji većinu glasova unutar izborne jedinice. Ovaj se sustav često naziva *winner-takes-all*, što na engleskom znači pobjednik uzima sve ili *First-Past-the-Post*. Samo kandidat s najviše glasova dobiva mandat, dok svi ostali ostaju bez zastupljenosti. Pobjednika je moguće odrediti relativnom i apsolutnom većinom. Kod relativne većine, pobjednik je onaj kandidat koji je osvojio najviše glasova, čak i ako nije osvojio više od 50 % ukupnog broja

glasova unutar izborne jedinice. Kod apsolutne većine potrebno je skupiti više od 50 % ukupnog broja glasova, a u slučaju izostanka takve potpore, održava se drugi krug između dva najuspješnija kandidata. Većinski sustav načelno više odražava volju birača. Kandidat koji osvoji najviše glasova u jedinica izravno dobiva mandat, stoga je povezanost između glasova birača i izabranog zastupnika jasnija nego u razmjernom sustavu.

### **2.1.3 Mješoviti sustav**

Mješoviti izborni sustav (engl. *mixed electoral system*) kombinira elemente većinskog i razmjernog izbornog sustava pri čemu je cilj iskoristiti prednosti oba sustava. Takvi mješoviti sustavi omogućuju da svaka izborna jedinica ima svog izravno izabranog predstavnika dok istovremeno osigurava proporcionalnost političke snage stranaka. U ovim sustavima glasovi za manje stranke imaju veću vjerojatnost rezultirati zastupničkim mjestom te ukupni sastav parlamenta bolje odražava raspodjelu glasova. Primjer države koja koristi mješoviti izborni sustav je Njemačka, čiji građani imaju pravo dva glasa, jedan za kandidata u pojedinom okrugu (većinski sustav), a drugi za stranačku listu (razmjerni sustav).

## **2.2 Proporcionalnost izbornog sustava**

Proporcionalnost izbornog sustava označava koliko vjerno raspodjela mandata u parlamentu odražava udio glasova koje su političke strane, odnosno liste, osvojile na izborima. U idealnom slučaju raspodjele bi trebale biti iste, ali je u praksi savršena proporcionalnost rijetko moguća zbog raznih tehničkih ograničenja u postupku izbora. Za kvantitativnu procjenu proporcionalnosti koriste se indeksi nerazmjernosti, od kojih je najpoznatiji Gallagherov indeks [6]. Gallagherov indeks izračunava se kao korijen iz polovine sume kvadrata

razlika između postotka osvojenih glasova i mandata za svaku stranku:

$$GI = \sqrt{\frac{1}{2} \sum_{i=1}^n (V_i - S_i)^2}. \quad (1)$$

U razmjernom sustavu, koji dodjeljuje više mandata po izornoj jedinici i primjenjuje proporcionalne formule raspodjele, odstupanja su mala, pa indeks tipično iznosi između 1 i 3. U većinskom sustavu velik broj glasova otpada jer ne osiguravaju pobjedu te to stvara veće nerazmjernosti između glasova i mandata. Stoga, indeks u takvim sustavima često prelazi 10.

### **2.3 Izborni sustav Republike Hrvatske**

Hrvatska koristi razmjerni izborni sustav uz mogućnost preferencijalnog glasovanja za izbor zastupnika u Hrvatski sabor. Na teritoriju Republike Hrvatske bira se 140 zastupnika u 10 geografskih izbornih jedinica, pri čemu svaka jedinica daje 14 zastupnika. Birači glasaju za stranačke liste, ali mogu dati i svoj preferencijalni glas jednom kandidatu s liste. Preferencijalno glasovanje prvi je puta primijenjeno na izborima za Europski parlament 2013. godine, a kandidat koji osvoji više od 10 % preferencijalnih glasova unutar svoje liste preskače redoslijed na listi i ima prednost u raspodjeli mandata. Mandati se raspoređuju prema D'Hondtovo metodi, uz izborni prag od 5 % po jedinici. Prema Gallagherovom indeksu, hrvatski je izborni sustav proporcionalan, ali ne i među najproporcionalnijima u Europi. Primjerice, gledajući parlamentarne izbore 2024. godine, indeks je iznosio 7,04, što ukazuje na umjerenu razinu proporcionalnosti.

## 3 Algoritam i Implementacija


### 3.1 Definicija problema i priprema podataka

U prethodnim je poglavljima ukratko predstavljena teorijska osnova izbornih sustava te njihovi učinci na proporcionalnost i reprezentativnost. U nastavku rada prikazan je razvoj računalnog modela namijenjenog praktičnoj analizi i usporedbi većinskog izbornog sustava. Primarni je cilj implementacije izgradnja simulacijskog okruženja s mogućnosti za generiranje i evaluaciju prijedloga razdiobe izbornih jedinica u Republici Hrvatskoj. Time se nastoji ispitati u kojoj mjeri većinski izborni sustav može udovoljiti temeljnim zahtjevima kao što su povezivost jedinica, uravnoteženost populacije te izbjegavanje nepravilnih oblika.

Implementacija se temelji na javno dostupnim podacima koji su preuzeti od Državnog izbornog povjerenstva Republike Hrvatske, pri čemu su podaci izvorno dani u tabličnom obliku. Prvotno je bilo potrebno provesti postupak geokodiranja kako bi svako biračko mjesto bilo povezano s odgovarajućim geografskim koordinatama. Potom su podaci strukturirani u GeoJSON format, što omogućuje njihovu daljnju obradu i vizualizaciju u GIS programskim sučeljima. Svi programski kodovi dostupni su javno na GitHub repozitoriju projekta [7].

Kao ulaz u algoritam koristi se Voronoi dijagram konstruiran na temelju geografskih lokacija biračkih mjesta. Voronoi dijagram definira particiju ravnine tako što ju dijeli na skup konveksnih poligona, pri čemu svaki od poligona obuhvaća područje u kojem su sve točke bliže jednoj točki zadanog skupa  $S$  nego bilo kojoj drugoj točki iz istog skupa. U razmatranom primjeru, svakoj se točki prostora pridružuje najbliže biračko mjesto. Primjer takvog dijagrama ilustriran je slikom 1, gdje svaka ćelija obuhvaća jedno biračko mjesto označeno

crvenom točkom, a sve točke unutar te ćelije najbliže su upravo tom biračkom mjestu.



Slika 1: Primjer Voronoi dijagrama.

Rezultirajuću strukturu moguće je interpretirati kao planarni graf čija se lica odnosno susjedstva sastoje od točaka najbližih pojedinom biračkom mjestu. Granice između susjedstava određene su skupom točaka jednakih udaljenosti od odgovarajućih biračkih mjesta, dok čvorove grafa čine točke ekvidistantne trima ili više susjedstava. Budući da je rijetkost da su čvorovi incidentni s više od tri brida, većina čvorova Voronoi dijagrama povezana je upravo trima bridovima.

Zbog planarnosti, moguće je definirati i njemu planaran dualni graf, koji ima ključnu ulogu u nadolazećim algoritmima jer omogućava da se nad biračkim mjestima provodi postupak particioniranja. Dualni graf sažima sve relevantne informacije o povezanosti, susjedstvu i udaljenosti između jedinica te bez njega algoritmi kasnije faze ne bi imali strukturirani ulaz potreban za daljnje optimizacije. Čvorovi duala odgovaraju biračkim mjestima te im se pridružuju atributi poput njihova susjedstva (u obliku geometrijskih likova), geografske koordinate, adresa i brojeva registriranih glasača. Bridovi duala proizlaze iz

njegove definicije: ako dva susjedstva dijele brid u izvornom grafu, tada u dualu oni postaju susjedni čvorovi povezani bridom. U razmatranom problemu bridovi dodatno nose atribut duljine koja se odnosi na duljinu originalnog brida iz Voronoi dijagrama, a ne na fizičku udaljenost između biračkih mjesta.

Očekivani izlaz, odnosno rješenje problema, definiran je trima zahtjevima:

1. Komponente izlazne particije moraju tvoriti povezane grafove;
2. Izlazna particija mora biti balansirana s obzirom na populaciju;
3. Komponente moraju imati što jednostavniji oblik.

Prvi zahtjev podrazumijeva da se iz svakog biračkog mjesta unutar jedne izborne jedinice mora moći doći do svakog drugog mjesta iste jedinice bez napuštanja njezina područja. Drugim riječima, izborne jedinice morat će činiti povezane komponente.

Drugi zahtjev odnosi se na balansiranost populacije. Broj birača unutar svake izborne jedinice smije odstupati najviše 5 % od očekivane srednje vrijednosti, sukladno važećim zakonskim propisima u Republici Hrvatskoj [8]. Formalnije, za svaku izbornu jedinicu vrijedi

$$\left| 1 - \frac{p}{\frac{P}{IJ}} \right| < 5\% \quad (2)$$

,

gdje je  $p$  ukupna populacija jedinice,  $P$  ukupna populacija države, a  $IJ$  broj izbornih jedinica.

Treći zahtjev, koji proširuje prvi zahtjev, reflektira preferenciju za jedinicama što pravilnijeg oblika, po mogućnosti konveksnog. Nepravilni oblici, osim što narušavaju geometrijsku regularnost, često upućuju na pokušaj manipulacije izbornim granicama (engl. *gerrymandering*) te ih je, kada je moguće, poželjno izbjeći.

Prva dva zahtjeva predstavljaju nužne (čvrste) uvjete koje rješenje mora zadovoljiti kako bi se smatralo ispravnim, dok treći zahtjev predstavlja meki uvjet i primjenjuje se samo na skup rješenja koja već zadovoljavaju prva dva uvjeta. Metrika za ocjenu svakog rješenja definira se ukupnom duljinom granica između izbornih jedinica. Najbolje moguće rješenje, koje minimizira spomenutu metriku, naziva se optimumom. Pronalazak optimuma predstavlja NP-težak problem, zbog čega se primjena heurističkih metoda i tehnika strojnog učenja prirodno nameće kao nužan pristup u pronalasku rješenja čija je kvaliteta što bliža optimalnom.

### **3.2 Opis faza algoritma**

Algoritam particioniranja provodi se u dvije faze. Potrebno je naglasiti da je riječ o prilagođenom rješenju razvijenom u okviru i za potrebe ovoga rada, koje ujedno predstavlja jedan od njegovih doprinosa.

U prvoj fazi, cilj je konstruirati inicijalnu podjelu što bolje kvalitete. U tu se svrhu primjenjuju postojeći algoritmi koji proizvode rješenja približna onima koja zadovoljavaju postavljene kriterije. Tijekom ove faze na sva se tri zahtjeva promatra kao na meke uvjete, čime je omogućena što šira pretraga prostora rješenja i veća fleksibilnost algoritama. Vremenska ograničenja u ovoj fazi nisu od primarne važnosti.

Druga je faza usmjerena na projekciju dobivenih rješenja u prostor prihvatljivih rješenja. U ovom se koraku nastoji uz minimalne promjene ispraviti sva kršenja prvog i drugog zahtjeva, pri čemu se zadržavaju svojstva inicijalne podjele koja ne narušavaju definirane uvjete. Dodatno, potrebno je provesti lokalne pretrage kojima se rješenje postupno približava optimumu. Tijekom ovog postupka potrebno je istovremeno voditi računa o eliminaciji nepravilnosti koje krše osnovne uvjete te očuvanju stabilnosti rješenja kako se ne bi uvodile



nove nepravilnosti prilikom optimizacije.

### 3.2.1 Faza inicijalne konstrukcije rješenja

Za algoritam prve faze odabran je algoritam KaFFPa (engl. Karlsruhe Fast Flow Partitioner) iz biblioteke KaHIP [9]. KaFFPa dijeli graf na  $k$  segmenata, gdje je  $k$  ulazni parametar, tako da se zadovolji zahtjev balansiranosti (do proizvoljne preciznosti), uz istodobnu minimizaciju *cijene* particije. Cijena je definirana kao ukupna težina bridova koji povezuju različite segmente konačne podjele. U kontekstu Voronoi dijagrama, upravo ti bridovi odgovaraju granicama između izbornih jedinica, što znači kako će KaFFPa nastojati zadovoljiti naš treći uvjet.

Unatoč spomenutim prednostima, ovaj algoritam ipak ne služi kao konačno rješenje zbog nekoliko ključnih ograničenja. Algoritam KaFFPa nužno ne zadovoljava prvi zahtjev povezanosti komponenti. Iako optimizacija trećeg uvjeta u pravilu podrazumijeva i povezanost komponenti (jer će graf s većim brojem odvojenih površina  $K$  uvijek imati veći opseg od grafa s manjim brojem površina  $L$ , gdje je  $L < K$ , pri optimalnoj podjeli), u praksi to nije zajamčeno. Drugi se zahtjev balansiranosti populacije pokazao problematičnim jer ga je u određenim slučajevima teško udovoljiti.

Primjerice, u promatranom slučaju na teritoriju Republike Hrvatske treba formirati  $K = 10$  izbornih jedinica, pri čemu prosječan broj birača po jedinici iznosi približno 350 000. Ako nakon inicijalne podjele jedna od jedinica obuhvati 400 000 birača, a druga jedinica samo 310 000, odstupanje iznosi više od dopuštenih  $\pm 5\%$ , odnosno 17 500 birača. U tom slučaju KaFFPa, radi postizanja minimizacije ukupnog opsega granica, zadržava neravnotežu između jedinica, budući da algoritam nema ugrađenu strogu penalizaciju za kršenje kriterija populacijske uravnoteženosti. Time formalno nije zadovoljen drugi zahtjev, a posljedično niti prvi; Korekcije nužne za usklađivanje broja birača

mogu dovesti do fragmentacije te nepovezanosti izbornih jedinica.

Upravo zbog spomenutih ograničenja, uvedena je druga faza algoritma, čija je svrha korektivni postupak kojim se početna rješenja dovode u prihvatljivu formu koja zadovoljava sve nužne uvjete.

### **3.2.2 Faza projekcije i lokalne optimizacije**

#### **Inicijalna raspodjela**

U početnom koraku druge faze potrebno je identificirati površine povezanih čvorova koji pripadaju istoj izornoj jedinici. Te površine nazivaju se klasterima. U ispravnom grafu svaka izborna jedinica odgovara jednom klasteru, dok u općenitom slučaju jedinica može biti predstavljena skupom više klastera. Na temelju identificiranih klastera, konstruira se novi graf postupkom stezanja (engl. *contraction*), pri čemu se svaki klaster reducira na jedan čvor. Pritom se akumuliraju sljedeći atributi:

1. populacija se sumira;
2. geometrijski oblici susjedstva unificiraju se u jedinstven oblik;
3. pripadnost jedinici, zajednička svim čvorovima klastera, prenosi se i postaje *boja* novog čvora.

Višestruki bridovi nastali ovim postupkom reduciraju se u jedan brid, kojemu se kao atribut pridružuje skup svih bridova koji ga sačinjavaju.

Rezultirajući stegnuti graf razlikuje se od izvornog po tomu što čvorovi predstavljaju klastere umjesto pojedinačnih biračkih mjesta, dok bridovi predstavljaju granice između klastera. Uz to, uvodi se i novo svojstvo kojim se svaki klaster označava kao reprezentativan ili inferioran član svoje boje odnosno

izborne jedinice. Svaka jedinica sadrži točno jedan reprezentativan klaster, onaj s najvećom populacijom, dok svi ostali klasteri iste boje postaju inferiorni.

Za razliku od dualnog grafa u kojem se mijenja isključivo boja čvora, atributi stegnutog grafa dinamički se mijenjaju u ovisnosti o raspodjeli biračkih mjesta. Stegnuti graf stoga predstavlja apstraktni prikaz podataka odnosno *pogled* na iste informacije kroz alternativno, kompaktnije sučelje.

### Razgradnja klastera

Cilj konstrukcije grafa u kojem je svaki čvor različite boje postiže se operacijom razgradnje inferiornih klastera, pri čemu se njihovi čvorovi redistribuiraju među superiornim susjedima.

Operacija razgradnje provodi se na originalnom grafu i ima za cilj redistribuciju svih čvorova klastera  $C$  prema njegovim susjednim klasterima. Za svaki se susjedni klaster  $S_i$  *a priori* određuje udio populacije klastera  $C$  koji će mu biti pridijeljen, tako da konačne populacije svih susjeda budu što bliže srednjoj vrijednosti. Očekivana populacija susjeda  $S_i$  nakon redistribucije definirana je formulom:

$$\hat{P}(S_i) = P(S_i) + P(C) * \frac{\max(0, \bar{P} - P(S_i))}{\sum_i^n \max(0, \bar{P} - P(S_i))}, \quad (3)$$

gdje je  $\bar{P}$  definiran kao

$$\bar{P} = \frac{P(C) + \sum_i^n P(S_i)}{n} \quad (4)$$

predstavlja prosječnu populaciju nakon podjele,  $P(S_i)$  trenutnu populaciju susjednog klastera, a  $P(C)$  ukupnu populaciju klastera koji se razgrađuje.

Nakon definiranja očekivanih populacija, algoritam se provodi na način sličan rebalansiranju. Razmatraju se isključivo granice klastera  $C$ , a populacijski kontrast definira se kao  $|\hat{P}(A) - P(A)|$ , umjesto kao  $|P(B) - P(A)|$  u standardnom postupku rebalansiranja. Kritična vrijednost za ovaj kontrast postavljena je na 0, čime je osigurana potpuna redistribucija svih čvorova razgrađivanog klastera.


### **Korekcija rješenja**

Algoritmi namijenjeni razrješavanju povezanosti, ponovnom balansiranju, te optimizaciji, temelje se na dinamičkoj analizi granica. Proces rebalansiranja se, među spomenutim procesima, izdvaja kao posebno važan, a sadrži temeljne ideje na kojima počivaju i svi ostali algoritmi ove faze, iako se kronološki ne izvršava prvi.

Razmotri li se pojedina granica, trivijalna operacija koja može biti od interesa jest premještanje čvora s jedne strane granice na drugu. Takva se operacija nikada ne primjenjuje na čvorove koji leže na granici, a prijenos većeg broja čvorova uvijek se može ostvariti sekvencijalnim prijenosom pojedinačnih čvorova. Premještanjem čvora neposredno se utječe na duljinu ukupne granice te na populacije klastera koje granica spaja. Također, u stegnutom grafu mogu nastati nove granice ili nestati postojeće, što u ovoj fazi neće igrati ulogu pri odlukama algoritma jer se operacije fokusiraju isključivo na identifikaciju i redistribuciju čvorova unutar klastera radi očuvanja povezanosti i približavanja populacijske ravnoteže.

Potrebno je osigurati da se izbjegne situacija u kojoj bi premještanjem čvora došlo do raspada nekog od klastera na dva dijela. Takav slučaj nastaje kada čvor kojeg oduzimamo klasteru predstavlja *most* u grafu. Za identifikaciju mostova koristi se jednostavna heuristička provjera. Čvor se smatra mostom


ako nije moguće povezati njegove susjede bez prolaska kroz sam čvor. Kako su čvorovi grafa povezani po fizičkoj udaljenosti, provjera se provodi pohlepnim algoritmom; Iz trenutnog se čvora pokušava doći do najbližeg neposjećenog susjeda (onaj koji je euklidski najbliži barem jednom od susjeda čvora koji je kandidat). Ako se u najviše  $2n$  koraka, gdje  $n$  označava očekivan broj susjeda (u Voronoi dijagramu ograničen odozgo i efektivno  $O(1)$ ), ne uspije posjetiti sve susjede, čvor se proglašava mostom. Ilustracija se nalazi na slici 2.



Slika 2: Identifikacija mosta - čvor koji razdvaja klaster na dva dijela

Opisana heuristika pouzdano identificira sve stvarne mostove, dok u rijetkim slučajevima može označiti i neki čvor koji to zapravo nije. Posljedice takve pogrešne klasifikacije zanemarive su, budući da dovode jedino do preskakanja spomenutog čvora, bez značajnog utjecaja na ostatak algoritma. Suprotna pogreška, neprepoznavanje pravoga mosta, ozbiljna je i može narušiti ispravnost cijelog postupka. Razlog rijetkim pogrešnim oznakama leži u


strukturni Voronoi dijagrama. Većina čvorova ima tri susjeda. U njegovu dualu to implicira da susjedi svakog čvora, osim čvora koji je most, moraju biti međusobno povezani barem jednim bridom, tvoreći lanac ili ciklus (u promatranom slučaju uvijek lanac jer barem jedan susjed pripada drugom klasteru). Algoritam u takvom slučaju u najviše  $2n - 2$  poteza pouzdano identificira čvor kao ne-most, što je ilustrirano na slici 3.



Slika 3: Primjer ne-mostnog čvora (susjedi ostaju međusobno povezani nakon uklanjanja)

U rijetkim geometrijskim konfiguracijama pojavljuje se Voronoi čvor s više od tri susjeda. (situacija u kojoj je neka točka u prostoru jednako udaljena od četiri ili više izbornih jedinica). Njegov dual tada stvara strukture poput one ilustrirane slikom 4.


U ovim slučajevima heuristika i dalje vraća ispravne rezultate, no moguće je da zahtijeva  $(n - 1 + k) * 2$  koraka da posjeti sve susjede, gdje  $k$  označava broj



Slika 4: Čvor s više od tri susjeda u Voronoi dijagramu.

dodatnih susjeda čvora koji utječu na identifikaciju čvora kao mosta u heuristici. Broj iteracija moguće je povećati, no budući da  $k$  nije moguće unaprijed odrediti, uspjeh nije zajamčen. U praksi takvi slučajevi gotovo nikada ne nastaju, budući da su biračka mjesta distribuirana na glatkoj površini  $\mathbb{R}^2$ . Diskretizacijom prostora nastaju potencijalne simetrije poput onih na slici 5, osobito grubom diskretizacijom. Na lijevoj je podslici prikazan problem simetrije koja nastaje diskretizacijom, a na desnoj je podslici detaljniji prikaz iste konfiguracije. Ovakve simetrije otežat će i povećati broj koraka potrebnih za identifikaciju mosta. Ipak, njihov je utjecaj na algoritam minimalan i može se kontrolirati blagim povećanjem iteracija.

Time je definiran prijelazni mehanizam među stanjima, pri čemu se stanjima smatraju pojedina rješenja, odnosno particije grafa. Cilj nije analizirati može li se nizom ovakvih operacija dosegnuti svako moguće stanje, već je interes



Slika 5: Simetrijski artefakti nastali zbog diskretizacije prostora.

usmjeren isključivo na lokalnu okolinu ulaznog rješenja definiranu skupom stanja dostupnih s pomoću spomenutih operacija. Nadalje, razmatraju se isključivo algoritmi koji promatraju jedan korak unaprijed, odabirući onaj prijelaz koji je za dano stanje najpovoljniji prema zadanom kriteriju.

Inspiracija za ovakav pristup problemu izvire iz fizikalnih procesa poput difuzije, gdje lokalna ponašanja čestica uzrokuju globalne trendove gibanja prema ekvilibriju. U promatranom slučaju, ekvilibriju odgovara raspodjela u kojoj su populacije klastera uravnotežene uz minimalne deformacije granica. Lokálnost operacija također dodatno omogućava paralelizaciju izvođenja, jer se svaka granica može obrađivati zasebno, pri čemu je potrebno fiksirati isključivo klastere koje pojedina granica dijeli.

### **Funkcija cijene i optimizacija**

U ovoj fazi prirodno se uvodi koncept *cijene* pomaka. Pomak koji izjednačava populacije susjednih klastera smatra se poželjnijim od onog koji povećava kontrast, dok pomak koji smanjuje duljinu granice doprinosi manjoj ukupnoj cijeni od onog koji je povećava. Cijena se definira kao suprotnost dobroti i kvantificira koliko je određeni pomak nepovoljan u kontekstu postavljenih



zahtjeva. Populacijska i granična cijena tretiraju se kao monotone funkcije pripadnih veličina. Središnje je pitanje kako ovako definirane funkcije kombinirati u jedinstvenu funkciju koja odražava prioritete algoritma.

Ako razlika u populacijama među klasterima premašuje kritičnu vrijednost, prioritet se daje izjednačavanju populacija; ako je razlika manja, prioritet postaje minimizacija duljine granica. U tom slučaju, mogli bismo uzeti da je naša funkcija približno konstantna u populaciji kada je razlika populacija manja od određene kritične vrijednosti, a približno konstantna u duljini inače. Ovaj kriterij odnosi se na akcije koje mijenjaju istu granicu, no želimo usporediti i akcije nad različitim granicama. Svejedno nam je koju od dvije granice ćemo smanjiti jer obje jednako doprinose ukupnoj granici. No, kada gledamo razlike u populaciji, koje ćemo radi jednostavnosti nazvati kontrastima, nije nam svejedno kojem kontrastu dati prioritet. Na taj način funkcija cijene može kontinuirano odražavati važnost oba kriterija, bez potrebe za rigidnim *ako-onda* (engl. *if-then*) pravilima, čime se zadržava fleksibilnost algoritma.

Analiza mogućih različitih slučajeva kontrasta može se sažeti na sljedeći način:

- a. *Jedan od kontrasta ispod je kritične vrijednosti, a drugi iznad.* – Prioritet se daje kontrastu iznad kritične vrijednosti;
- b. *Oba kontrasta iznad su kritične vrijednosti* – Prioritet se daje kontrastu čije smanjenje u idućem potezu, doprinosi većoj ukupnoj uravnoteženosti;
- c. *Oba kontrasta ispod su kritične vrijednosti ili približno jednako smanjuju neravnotežu* – Prioritet se daje smanjenju duljine granica.

Odabir prioriteta ne temelji se isključivo na trenutačnom iznosu kontrasta kako bi se izbjegao zastoj algoritma u lokalnim minimumima. Pretpostavka je da je

globalni ekvilibrij moguć, ali nije zajamčeno da se između svaka dva klastera odmah može postići lokalni ekvilibrij.

Formalni zahtjevi funkcije cijene su sljedeći:

- a. Rast funkcije u duljini granice  $D$  mora biti znatno sporiji od rasta funkcije u populaciji  $k$ , osim kada su populacijski kontrasti ispod kritične vrijednosti  $K$ , kako bi algoritam prvenstveno rješavao veće populacijske neravnoteže;
- b. Funkcija mora kvantificirati relativnu cijenu pomaka između stanja, tako da bilo koji pomak koji smanjuje populacijsku neravnotežu ili duljinu granice smanjuje ukupnu cijenu;
- c. Funkcija mora biti rastuća u duljini granice jer u slučaju male razlike u populaciji, trošak povezan s duljinom granica  $D$  postaje dominantan. Time se potiče stvaranje kompaktnih i pravilnih oblika izbornih jedinica.

Jedna od mogućih implementacija opisane funkcije koristi kombinaciju polinoma, aktivacijske funkcije  $ReLU$  i  $L$ -norme:

$$f = L_n(ReLU(K - k)^p, s * D^{\frac{1}{r}}), \quad (5)$$


, gdje je

$$L_n(x, y) = \sqrt[n]{x^n + y^n},$$

$$\lim_{n \rightarrow \infty} (L_n) = max.$$

Parametri funkcije, uključujući stupanj polinoma  $p$ , potencija  $\frac{1}{r}$ , red norme  $n$  te skaliranje  $s$ , odabrani su eksperimentalno kako bi se postigla ravnoteža

između izjednačavanja populacije i minimizacije duljina granica. Funkcija je vizualizirana slikom 6. Vizualizirana funkcija ima blago zakrivljen oblik koji se spušta prema ishodištu, a zatim se, rastom njenih varijabli, naglo uspinje prema pozitivnim vrijednostima.



Slika 6: 3D površinski graf funkcije cijene

U tom kontekstu, uočeno je da vrijednost  $n = 2$  osigurava zadovoljavajuću ravnotežu između kriterija. U situacijama kada su populacijski kontrasti iznad dopuštenih granica, prioritet ostaje na smanjenju populacijskog kontrasta, ali kada postoji izbor preferiraju se pomaci koji smanjuju i populacijski kontrast i duljinu granica, čime se istovremeno poboljšava već ranije spomenuta ravnoteža i kompaktno oblikovanje jedinica.

Funkcija cijene osigurava konvergenciju algoritma jer svaka iteracija smanjuje ukupnu cijenu. Konačno rješenje ne mora nužno biti optimum pa se

stoga algoritam i provodi s nekoliko različitih postavki parametara, od najstrožih prema najblažima, pri čemu se prihvaća prvo rješenje koje zadovoljava sve čvrste zahtjeve.

Kod pretraživanja akcija ukupan broj pomaka jednak je zbroju akcija svih granica. Većina granica ostaje nepromijenjena nakon svakog pomaka, stoga se ponovno izračunavanje provodi samo za granice povezane s promijenjenim klasterima. Implementirana je struktura *turnir stabla*, gdje se listovi odnose na granice i njihove najbolje akcije. Ažuriranje stabla nakon promjene stanja složenosti je  $O(m \cdot n)$ , dok je složenost ažuriranja roditeljskih čvorova  $O(m \cdot \log M)$ . Efektivna složenost iteracije stoga je približno  $O(n)$ .

### 3.3 Zaključak


Opisani postupak odlikuje se izrazitom robusnošću na nepravilnosti ulaznog grafa, uz nisku računalnu složenost koja se postiže uz cijenu određenog stupnja neoptimalnosti i relativno ograničenog prostora pretraživanja.

Temeljna ideja algoritma zasniva se na principu difuzije, pri čemu je pretpostavka da će lokalno izjednačavanje koncentracija dovesti do postizanja globalne jednakosti. Ulazne granice tretiraju se kao elastične opne koje se opiru prekomjernim deformacijama, čime su očuvana strukturna svojstva podjele. Funkcija cijene pritom modelira ravnotežu između „elastičnosti“ granica i „populacijske struje“ uzrokovane procesom difuzije.

## 4 Simulacija alternativnih izbornih sustava

### 4.1 Nedijeljene komponente izbornih listi

Pri simulaciji izbora temeljenoj na podacima proizašlima iz drugačije podjele teritorija u izborne jedinice od one trenutno korištene u izbornom sustavu postoji problem u računanju broja glasova po novim jedinicama. Iako stranke često koaliraju na nacionalnoj razini te u svim jedinicama formiraju zajedničku listu, nerijetko se događa i suprotno, da u pojedinim izbornim jedinicama ne izađu zajedno ili izađu s drugim koalicijskim partnerima. Najčešći razlog tome je postojanje stranaka regionalnog karaktera. Teoretski, stranke bi mogle koalirati u jednoj jedinici, a biti konkurenti u drugoj. Različite liste predstavljaju problem jer jedna izborna jedinica nove raspodjele općenito sadržava biračka mjesta iz više originalnih jedinica, pa su neki glasovi u njoj dani za različite liste koje sačinjavaju neke zajedničke, a neke različite stranke. Zato rezultate nema smisla izražavati po listama.



Slika 7: Primjer različitog sastava listi u 5 izbornih jedinica

Nažalost, nije moguće potpuno pouzdano utvrditi koliki je udio birača dao glas nekoj izornoj listi zbog koje od stranaka na listi. Radi smanjenja pogreške unesene razdvajanjem, liste smo umjesto potpuno (na stranke) dekomponirali na *nedijeljene komponente* definirane kao najveći mogući skup stranaka takav

da su stranke iz tog skupa zajedno na listi u svakoj izbornoj jedinici. Pritom "najveći" znači da ne postoji pravi nadskup nedijeljene komponente koji je i sam nedijeljena komponenta. U primjeru na slici 7, svaki označeni skup predstavlja jednu izbornu listu u odgovarajućoj jedinici. Nedijeljene komponente u ovom slučaju su skupovi stranaka {A,B}, {C,D} i {E}. Nerijetko jedna stranka sama čini komponentu.

Primjena na parlamentarnim izborima 2024. godine daje ukupno 38 komponenti. Svaka je lista sačinjena od jedne ili više komponenti bez presjeka. Sada u svakoj trenutačnoj izbornoj jedinici za svaku listu treba procijeniti koliki bi udio ukupno osvojenih glasova dobila pojedina komponenta u listi. Za to postoji nekoliko metoda:

1. Procjena prema anketama;
2. Zanimarivanje utjecaja malih komponenti;
3. Procjena prema preferencijalnim glasovima.

U Hrvatskoj postoji nekoliko agencija koje redovito provode ankete za procjenjuju potpore birača po strankama. Ankete su prethodnih godina precizno predviđale izborne rezultate. Procijenjeni broj glasova za komponentu  $K_i$  je:

$$G(K_i) = G(L) \frac{\sum_{s \in K_i} w_s}{\sum_{s \in L} w_s} \quad (6)$$

gdje je  $w_s$  udio birača koji po anketi podupiru stranku  $s$  ili 0 ako ne postoje podaci za tu stranku. Međutim, obično se objavljuju samo udjeli potpore među ispitanicima za nekoliko najvećih stranaka. Ako one ne koaliraju međusobno, ova se metoda svodi na metodu zanemarivanja utjecaja malih komponenti.

Ako lista sadrži jednu ili nekoliko stranaka vrlo malih u odnosu na najveću stranku u listi, u slučaju nedostatka podataka za informiraniju podjelu sve glasove pripisuje se najvećoj komponenti. Time se unosi pogreška u izračun indeksa, no rezultat je zadovoljavajuć za okvirnu procjenu odnosa indeksa u različitim sustavima, pogotovo ako se zanemarena komponenta sastoji od samo jedne vrlo male stranke koja ne prelazi izborni prag.

U procjeni udjela prema preferencijalnim glasovima broj glasova komponente  $K_i$  liste  $L$  računa se kao:

$$G(K_i) = G(L) \frac{pref(K_i)}{\sum_{K_j \subseteq L} pref(K_j)} \quad (7)$$

gdje je  $G(L)$  ukupan broj osvojenih glasova liste, a  $pref(K)$  ukupan broj preferencijalnih glasova koje su osvojili pojedinačni kandidati na listi koji su članovi neke od stranaka u komponenti  $K$ . Ova metoda također nije idealna jer preferencijalni glasovi nisu obavezni. Od važećih listića na parlamentarnim izborima 2024. samo je na 63,98% bio označen i preferencijalni glas [10]. Procjena je precizna samo pod pretpostavkom da taj udio ne varira značajno među biračima različitih stranaka. Također, pouzdani i organizirani podaci o članstvu izbornih kandidata u strankama bili su nam dostupni samo za izabrane zastupnike. Stoga smo se opredijelili za kombinaciju procjene prema anketama i zanemarivanja utjecaja malih komponenti uz korekciju za liste koje sadrže IDS i PGS. Zbog izrazitog regionalnog karaktera tih stranaka smatrali smo da čine dominantnu komponentu u svojim izbornim listama za VII i VII izbornu jedinicu, a da im je doprinos glasovima listi u ostalim jedinicama relativno malen.

## 4.2 Koncentracija vlasti i Herfindahl-Hirschmanov indeks

Proporcionalnost je važno, ali ne i apsolutno mjerilo kvalitete izbornog sustava, primjerice, izborni pragovi smanjuju proporcionalnost jer dio glasova za vrlo male stranke propada, ali ipak se uvode jer sprječavaju pretjeranu fragmentaciju mandata. Visoko fragmentiran sastav parlamenta može dovesti do neučinkovitosti zbog prevelikog broja različitih stranaka čije je stavove u praksi teško usuglasiti. Ponekad dodatno poboljšavanje proporcionalnosti nije vrijedno rizika formiranja disfunkcionalne vlasti pa stoga osim indeksa proporcionalnosti želimo izračunati i kvantitativnu mjeru razine fragmentacije. U tu svrhu smo iskoristili Herfindahl-Hirschmanov indeks (HHI)[11, 12], definiran izrazom:

$$HHI = \sum m_i^2 \in (0, 1] \quad (8)$$


gdje su  $m_i$  udjeli osvojenih mandata komponenti u ukupnom broju mandata. Primjena HHI uz korištenje tržišnih udjela umjesto udjela u broju mandata uobičajena je u ekonomiji. Agencije za zaštitu tržišnog natjecanja poput AZTN u Hrvatskoj koriste ga pri procjeni utjecaja spajanja i akvizicija velikih tvrtki na tržišno natjecanje i ne dopuštaju ih ako je HHI iznad određene granice. Iako se primjenjuje uglavnom u ekonomiji, korišten je i kao mjerilo konkurencije u politici [13]. U našem slučaju prenizak HHI ukazuje na potencijalne probleme s fragmentacijom.




## 5 Rezultati

### 5.1 Simulirani većinski sustavi


Proveli smo podjelu teritorija Republike Hrvatske na 100, 110, 120, 130 i 140 izbornih jedinica. Značajne razlike u prostornoj veličini jedinica posljedica su neravnomjerne gustoće naseljenosti. Važno je da su odstupanja među jedinicama u broju birača što manja. Generirane podjele prikazane su redom na slikama 8 (100 izbornih jedinica), 9 (110 izbornih jedinica), 10 (120 izbornih jedinica), 11 (130 izbornih jedinica), te konačno na slici 12 za 140 izbornih jedinica, koliko zastupnika iz teritorijalne Hrvatske trenutačno broji Hrvatski sabor. Za svaku raspodjelu određen je sastav parlamenta upotrebom većinskog sustava s relativnom većinom.




Slika 8: Podjela na 100 jedinica




Slika 9: Podjela na 110 jedinica



Slika 10: Podjela na 120 jedinica



Slika 11: Podjela na 130 jedinica



Slika 12: Podjela na 140 jedinica

## 5.2 Osvojeni mandati

U nastavku, u tablici 1, prikazani su osvojeni mandati po nedijeljenim komponentama za svaki simulirani sustav te su izračunati indeksi za usporedbu s trenutačnim izbornim sustavom. Pri izračunima za trenutačni sustav nisu uračunati zastupnici manjina i birača iz inozemstva odabrani u XI. i XII. izbornoj jedinici, već samo zastupnici izabrani u teritorijalnim jedinicama. Zastupnici koji su u međuvremenu promijenili stranku promatraju se i dalje kao članovi stranke i liste u čijem su sastavu izašli na izbore.

Zbog preglednosti, koriste se sljedeća kraća imena za komponente lista ili stranke koje same čine komponentu umjesto službenih punih naziva:

- **HDZ i partneri** (Hrvatska stranka umirovljenika - HSU, Hrvatska demokratska zajednica - HDZ, Hrvatska narodna stranka - Liberalni demokrati - HNS, Hrvatska Demokršćanska stranka - HDS, Hrvatska socijalno - liberalna stranka - HSLS)
- **SDP i partneri** (Socijaldemokratska partija Hrvatske - SDP, Centar, "Dalija Orešković i ljudi s imenom i prezimenom" - "DO i SIP", Hrvatska seljačka stranka - HSS, Građansko-liberalni savez - GLAS)
- **DP i PiP** (Domovinski pokret - DP, Pravo i pravda)
- **Most i partneri** (Most, Hrvatski suverenisti, Hrvatska konzervativna stranka - HKS, Nezavisna lista mladih - NLM)
- **Možemo!** (Možemo! - politička platforma)
- **IDS i PGS** (Primorsko goranski savez - PGS, Istarski demokratski sabor - IDS)
- **NPS** (Nezavisna platforma sjevera - NPS)

Tablica 1: Osvojeni mandati u većinskim sustavima

|                   | Broj izbornih jedinica |     |     |     |     | Stvarni rezultati                 |
|-------------------|------------------------|-----|-----|-----|-----|-----------------------------------|
|                   | 100                    | 110 | 120 | 130 | 140 |                                   |
| HDZ i partneri    | 67                     | 77  | 82  | 92  | 97  | 58 (bez XII. jedinice)            |
| SDP i partneri    | 27                     | 28  | 31  | 31  | 34  | 42 (uz Reformiste)                |
| Možemo!           | 2                      | 0   | 0   | 1   | 1   | 10 (uz Hoćemo pravedno)           |
| NPS               | 2                      | 3   | 3   | 3   | 3   | 2                                 |
| IDS / PGS         | 1                      | 1   | 2   | 2   | 3   | 2 <sup>1</sup>                    |
| Fokus / Republika | 1                      | 1   | 1   | 0   | 1   | 1                                 |
| DP / PiP          | 0                      | 0   | 1   | 1   | 1   | 7 (do 14 s različitim partnerima) |
| Most i partneri   | 0                      | 0   | 0   | 0   | 0   | 11                                |

Izračuni Gallagherovom i Herfindahl-Hirschmanov indeksa za simulirane sustave, te usporedba s trenutnim sustavom, prikazani su u tablici 2.

Tablica 2: Gallagherov i Herfindahl-Hirschmanov indeks za simulirane sustave

|           | Broj izbornih jedinica |       |       |       |       | Trenutačni sustav |      |
|-----------|------------------------|-------|-------|-------|-------|-------------------|------|
|           | 100                    | 110   | 120   | 130   | 140   |                   |      |
| Gallagher | 25.83                  | 28.08 | 26.85 | 28.39 | 27.40 | 7.04              | [14] |
| HHI       | 0.52                   | 0.56  | 0.53  | 0.56  | 0.54  | 0.28              |      |

<sup>1</sup>IDS i PGS su na izbornoj listi sa strankama Unija Kvarnera, Istarska stranka umirovljenika - Partito Istriano dei pensionati, Socijaldemokrati, Narodna Stranka - Reformisti, Demokrati i Hrvatski Laburisti osvojili ukupno dva mandata.

## 6 Zaključak

U ovome je radu razvijena i implementirana računalna metoda za rekonfiguraciju izbornih jedinica Republike Hrvatske primjenjiva na većinski izborni sustav. Predložena metoda sastoji se od dvofaznog algoritma, pri čemu se u prvoj fazi dolazi do inicijalne podjele algoritmom KaFFPa, a druga faza primjenjuje heurističke postupke za projekciju u prostor prihvatljivih rješenja te lokalnu optimizaciju. Osmišljena funkcija cijene integrira populacijski kontrast te duljinu granica, što omogućuje fleksibilnu optimizaciju prema zadanim kriterijima.

Rezultati pokazuju kako je moguće konstruirati većinski izborni sustav koji zadovoljava ključna zakonski propisana ograničenja. Evaluacija simulacijama temeljenima na rezultatima parlamentarnih izbora 2024. godine pokazuje da većinski sustav daje prednost malim strankama s koncentriranim biračkim tijelom te dvjema najvećim strankama u Hrvatskoj. Ostale velike stranke ostvarile bi iznenađujuće loše rezultate jer su njihovi birači raspoređeni u mnogo jedinica u kojima neka druga stranka ima većinu. Vrlo visoke vrijednosti Gallagherovog indeksa pokazuju da je potpuno većinski sustav nepovoljno rješenje, barem uz određivanje pobjednika relativnom većinom. Postoje države koje imaju većinski izborni sustav i vrlo nisku disproportionalnost, no to je vjerojatno posljedica opstanka samo stranaka prilagođenih takvom sustavu nakon njegove duge uporabe. Primjerice, postoji samo nekoliko velikih stranki kao u SAD-u, a sve su manje stranke regionalnog karaktera. Koncentracija vlasti je visoka u simuliranim sustavima. U daljnjem radu vrijedi ispitati učinak mješovitih sustava i proporcionalnih sustava s različitim brojem izbornih jedinica.

Buduća istraživanja mogu, primjerice, proširiti metodu na mješovite sustave, uključiti dodatno ograničenje u kontekstu administrativnih jedinica Hrvatske te analizirati dinamičke aspekte rekonfiguracije kroz više izbornih

ciklusa. Predloženi algoritam služi i kao inspiracija prema računalno potpomognutom dizajnu izbornih sustava, omogućujući objektivnu evaluaciju različitih konfiguracija kao i njihovih političkih posljedica.

## 7 Literatura

- [1] William H. Riker. The two-party system and duverger's law: An essay on the history of political science. *The American Political Science Review*, 76(4):753–766, 1982.
- [2] Jay Crush. Electoral systems and stability in divided societies. *International Relations Journal*, 21(11):121–155, 2013.
- [3] Bože Bradarić and Domagoj Madunić. Povijest parlamentarnih demokratskih izbora u republici hrvatskoj i načelo jednakosti izbornog prava. *Pravnik: časopis za pravna i društvena pitanja*, 58(110):173–196, 2024.
- [4] Gordana Iličić. Razumijevanje, vrste i strukturni elementi izbornih sustava. *Hum: časopis Filozofskog fakulteta Sveučilišta u Mostaru*, 9(11.-12.):156–171, 2014.
- [5] Zakon.hr. Zakon o izborima zastupnika u hrvatski sabor (pročišćeni tekst zakona). <https://www.zakon.hr/z/355/zakon-o-izborima-zastupnika-u-hrvatski-sabor>, 2025. Zadnji pristup: 29. 8. 2025.
- [6] Michael Gallagher. Proportionality, disproportionality and electoral systems. *Electoral Studies*, 10(1):33–51, 1991.
- [7] AXork99. Projektr\_2024-2025. [https://github.com/AXork99/ProjektR\\_2024-2025](https://github.com/AXork99/ProjektR_2024-2025), 2025. Zadnji pristup: 29. 8. 2025.
- [8] Zakon.hr. Zakon o izbornim jedinicama za izbor zastupnika u hrvatski sabor. <https://www.zakon.hr/c/zakon/58543/n-114-2023-> (4. 10. 2023.),



-zakon-o-izbornim-jedinicama-za-izbor-zastupnika-u-hrvatski-sabor, 2023. Zadnji pristup: 29. 8. 2025.

- [9] Peter Sanders and Christian Schulz. Think locally, act globally: Highly balanced graph partitioning. In *Experimental Algorithms, 12th International Symposium, SEA 2013, Rome, Italy, June 5-7, 2013. Proceedings*, volume 7933, pages 164–175. Springer, 2013.
- [10] Državno izborno povjerenstvo. Izvješće o provedenim izborima za zastupnike u hrvatski sabor 2024. [https://www.izbori.hr/site/UserDocsImages/2024/Izbori\\_za\\_zastupnike\\_u\\_Hrvatski\\_sabor/Rezultati/Izvje%C5%A1%C4%87e%20o%20provedenim%20izborima%20za%20zastupnike%20u%20Hrvatski%20sabor%202024.pdf](https://www.izbori.hr/site/UserDocsImages/2024/Izbori_za_zastupnike_u_Hrvatski_sabor/Rezultati/Izvje%C5%A1%C4%87e%20o%20provedenim%20izborima%20za%20zastupnike%20u%20Hrvatski%20sabor%202024.pdf), 2024. Zadnji pristup: 29. 8. 2025.
- [11] Albert O Hirschman. *National power and the structure of foreign trade*, volume 105. Univ of California Press, 1980.
- [12] Orris C Herfindahl. *Concentration in the steel industry*. Columbia university, 1997.
- [13] Jahen F. Rezki. Political competition and economic performance: evidence from indonesia. *Economics of Governance*, 23(2):83–114, June 2022.
- [14] World Population Review. Gallagher index by country 2025. <https://worldpopulationreview.com/country-rankings/gallagher-index-by-country>, 2025. Zadnji pristup: 29. 8. 2025.
- [15] Kristian Sabo, Rudolf Scitovski, and Petar Taler. Ravnomjerna raspodjela broja birača po izbornim jedinicama temeljem matematičkog modela. *Hrvatska i komparativna javna uprava*, 12(1):229–249, 2012.

- [16] Kristian Sabo and Rudolf Scitovski. Nova metoda za definiranje izbornih jedinica u hrvatskoj. *Hrvatska i komparativna javna uprava*, 23(4):645–672, 2023.

## Sažetak

**Autori:** Nikola Colnar, Mislav Hlupić

**Naslov:** Metoda za rekonfiguraciju izbornih jedinica s implementacijom u kontekstu izbornog sustava Republike Hrvatske

U ovom radu razvijen je računalni pristup za rekonfiguraciju izbornih jedinica Republike Hrvatske. Predložena metoda kombinira KaFFPa algoritam te heurističke postupke za lokalnu optimizaciju, uz funkciju cijene koja objedinjuje populacijski kontrast te duljinu granica. Simulacije pokazuju da je moguće postići povezane jedinice, populacijski balans te geometrijsku regularnost, uz prihvatljivu računalnu složenost. Rješenje je evaluirano simulacijom izbornih rezultata temeljenoj na rezultatima parlamentarnih izbora 2024. godine te su prikazani osvojeni mandati po većinskom izbornom sustavu.

**Ključne riječi:** izborni sustav; rekonfiguracija izbornih jedinica; većinski izborni sustav; simulacija izbora

## Summary

**Authors:** Nikola Colnar, Mislav Hlupić

**Title:** Method for Redistricting Electoral Units with Implementation in the Context of the Croatian Electoral System

This paper presents a computational approach for the reconfiguration of electoral districts in the Republic of Croatia. The proposed method combines the KaFFPa algorithm with heuristic procedures for local optimization, using a cost function that integrates population disparity and boundary length. Simulations demonstrate that it is possible to achieve contiguous districts, population balance, and geometric regularity, while maintaining acceptable computational complexity. The solution is evaluated through an election simulation based on the results of the 2024 parliamentary elections, with the distribution of seats presented under a majoritarian electoral system.

**Key words:** electoral system; electoral district reconfiguration; majoritarian electoral system; election simulation